Slide 01/21

我今天要介紹的這篇 Paper 是 "IIANet: An Intra- and Inter-Modality Attention Network for Audio-Visual Speech Separation"
這篇論文發表在 ICML 2024，這項研究的核心目標是要解決「雞尾酒會問題 Cocktail Party Problem」
也就是在多人同時說話的環境中，把某一個目標說話者的聲音分離出來
而它的做法是引入視覺資訊，也就是說話者的嘴唇動作，來輔助音訊的分離
接下來我會先簡單介紹這篇 Paper 的研究背景，然後再說明作者提出的方法以及實驗結果

Slide 02/21

首先先看一下研究背景，語音分離的任務可以分成兩類
第一類是 Audio-Only Speech Separation，也就是只靠聲音訊號去做分離
第二類是這篇論文處理的 Audio-Visual Speech Separation
　　也就是同時利用聲音和說話者的臉部或唇部影像
之所以要加入視覺，是因為嘴唇的動作跟語音的內容有很強的時間對應關係
所以當背景噪音很大、或是有多個人同時說話的時候
視覺可以提供一個不會被聲音干擾的線索
因此在實際應用上，這個技術可以用在助聽器、視訊會議的降噪
　　自動語音辨識的前處理，以及影音內容的後製

Slide 03/21

接下來回顧一下過去的方法，會遇到兩個主要的瓶頸
第一個問題是單一時間尺度的融合：過去的模型，包含前一個 SOTA CTCNet
　　雖然在音訊分支裡面有做多尺度的特徵提取
　　但是在跟視覺融合的時候，它們最後都收斂到最細的那一個尺度才做融合
問題是，語音的資訊本身是跨尺度的
　　音素的變化是毫秒級的，但一個字、一個語調的變化則是幾百毫秒級的
　　只在一個尺度上融合，就沒辦法同時對齊這些不同時間長度的線索
第二個問題是缺乏選擇性注意力
過去的做法大多是把視覺特徵直接 Concatenate 到音訊特徵上
　　但這種做法是無條件地把所有視覺資訊都灌進去
模型沒有辦法自己決定哪些視覺線索該被強化、哪些該被抑制
　　而且 Concatenation 會讓通道數大幅增加

這也是 CTCNet 的 MACs（Multiply-Accumulate Operations）高達 167.1 G 的主要原因

Slide 04/21

為了解決上述這些問題，作者提出了 IIANet 這個架構
它的設計靈感來自人腦處理視聽訊息的方式
在神經科學上，人腦的視聽整合並不是只發生在一個地方，而是分層進行的
在比較高的層級，例如視丘跟聯合皮質，處理的是比較抽象的、全域的訊息
在比較低的層級，例如初級聽覺皮質 A1 跟初級視覺皮質 V1
　　處理的則是比較細節的、局部的訊息
所以作者就把這個概念對應成兩種 Attention
第一種是 IntraA，也就是同一個模態內部的 Top-Down Attention
第二種是 InterA，也就是跨模態之間的 Attention
而且它分別被部署在 Top、Middle、Bottom 三個層級
這邊要特別說明一下變數的定義
a 代表音訊特徵，v 代表視覺特徵，下標 i 代表第幾個尺度
整體的流程就是：先分別編碼音訊跟視覺
然後在分離網路裡面反覆做這些 Attention 融合，最後再解碼還原成波形

Slide 05/21

接下來這一頁是問題的數學定義以及整體的 Pipeline
輸入是一段混合的音訊波形，以及對應說話者的唇部影像序列
模型的目標是估計出目標說話者的乾淨語音
它採用的是 Mask-based 的做法，也就是模型不直接輸出波形，而是輸出一個 Mask
再把這個 Mask 乘回混合訊號的特徵上，最後才解碼回時域波形
從這張 Fig. 1(A) 可以看到整體的資料流向
上面那一路是視覺，下面那一路是音訊，中間就是它們反覆交互的地方

Slide 06/21

整個架構其實可以拆成四個模組
第一個是 Audio Encoder，用一維卷積把波形轉成音訊特徵
第二個是 Video Encoder，這裡使用的是預訓練好的唇讀模型來擷取唇部動作特徵
第三個是 Separation Network，這是整篇論文的核心，也就是所有 Attention 機制發生的地方

第四個是 Audio Decoder，把 Mask 作用後的特徵還原成分離後的波形
要特別提的是，這篇論文的貢獻完全集中在第三個模組
Encoder 跟 Decoder 都是沿用既有的設計，所以效能的提升可以確定是來自融合策略本身

Slide 07/21

接下來我們細看分離網路的運作流程，可以參考右邊的 Fig. 1(B)
第一步是多尺度的特徵提取
音訊跟視覺分支都會各自透過下採樣，建立出 D 個不同時間解析度的特徵
這篇論文中 D 設為 4
第二步是在最頂層做跨模態的融合，也就是 InterA-T
這一步處理的是最抽象、時間跨度最長的全域資訊
讓兩個模態先在高層取得一個共同的語意脈絡

Slide 08/21

接著是第三到第五步
第三步是 Top-Down 的融合過程，這裡會用到 IntraA 跟 InterA-M
模型會把高層的特徵往下傳，去調節每一個尺度的低層特徵
同時在每一個中間尺度都做一次視覺到音訊的融合
第四步是在最細的尺度做 InterA-B，這是唯一一個雙向的融合，模擬的是視丘的角色
第五步是 Cycle，也就是把整個視聽融合的流程重複 N_F 次
之後音訊特徵還會再單獨迭代 N_S 次，讓它有足夠的深度去精修 Mask
所以這個架構的參數其實是重複使用的，這也是它能維持很小模型的原因之一

Slide 09/21

接下來這一頁是 InterA-T，也就是最頂層的跨模態注意力
從公式可以看到，它的運算其實非常單純
橘色標示的 p_i 代表的是經過投影後的另一個模態的特徵
藍色標示的 σ(Q(·)) 則是先做一次映射，再通過 Sigmoid 函數，把數值壓縮到 0 到 1 之間
接著把這個結果跟原本的特徵做 Element-wise 的相乘
換句話說，這就是一個 Gating 機制
另一個模態的特徵不是被直接加進來，而是變成一個閘門
去決定哪些通道要被保留、哪些要被抑制

這邊要特別強調，作者在論文的註腳裡面有明確說明
這裡的 Attention 跟 Transformer 的 Self-Attention 是無關的
它沒有 Query、Key、Value，也沒有矩陣相乘，所以計算量非常低
這也是為什麼 IIANet 的 MACs 可以壓到只有 CTCNet 的 11%

Slide 10/21

接下來這一頁是 IntraA，也就是模態內部的 Top-Down Attention
作者在這裡提出的是一個叫做 φ 的融合函數
它的做法是把來自高層的全域特徵，跟當前層的局部特徵結合起來
特別的地方是它同時保留了 Multiplicative 的 Gating 跟 Additive 的殘差分支
這個機制在音訊分支跟視覺分支都各自部署了一次
那它跟 TDANet 的差別在哪裡呢
TDANet 使用的是只有乘法的版本，作者把它記為 φ'
從 Appendix A 的實驗可以看到，使用 φ 是 16.0 dB，而使用 φ' 只有 14.7 dB
差了 1.3 dB，這證明多保留一個 Additive 分支是值得的
因為純乘法的 Gating 如果閘門值接近 0，資訊就會被完全抹掉
而加法分支可以保留一條資訊的旁路

Slide 11/21

接下來這一頁是 InterA-M，也就是中間層級的跨模態注意力
它的公式形式跟 InterA-T 類似，同樣是 Sigmoid Gating 加上元素相乘
但有兩個關鍵的差別
第一，它是單向的，只有視覺去調節音訊，沒有反方向
作者的解釋是，最終的目標輸出是音訊，所以視覺應該扮演輔助調節的角色
第二，它被部署在每一個中間尺度上
這正是這篇論文用來解決第一個 Research Gap 的關鍵設計
融合不再只發生在單一尺度，而是貫穿所有的時間解析度

Slide 12/21

接下來是 InterA-B，也就是最底層的跨模態注意力

它跟前面兩個最大的不同是，它是雙向的，視覺跟音訊會互相調節
而且它只被部署在最細的那一個尺度
在運算上它除了 Gating 之外，還額外加了一個殘差相加
作者用視丘來類比這個模組
視丘是感官訊號進入大腦的中繼站，是最早、也是雙向交互最密集的地方
所以在架構的最底層做雙向融合，對應的就是這個角色

Slide 13/21

接下來介紹本篇 Paper 的資料集與實驗設定
作者使用了三個標準的視聽語音分離資料集，分別是 LRS2、LRS3 以及 VoxCeleb2
其中 VoxCeleb2 是最困難的
因為它是從 YouTube 收集的真實場景影片，噪音跟拍攝角度的變化都比較大
在訓練設定上，使用 Adam Optimizer，Learning Rate 設為 1e-3
評估指標主要是 SI-SNRi，也就是尺度不變訊噪比的改善量，數值越高越好
在超參數上，尺度數 D 設為 4，通道數為 512
融合週期 N_F 設為 4，音訊迭代 N_S 設為 12
而 IIANet-fast 這個輕量版本，就是把 N_S 從 12 減半成 6
硬體則使用了 8 張 RTX 4090，Batch Size 為 6

Slide 14/21

接下來是實驗結果，我們先看分離品質的部分，也就是 Table 1
這張表比較了 IIANet 跟多個 Baseline
包含 AVConvTasNet、AVLiT，以及前一個 SOTA CTCNet
先看 LRS2 的 SI-SNRi，CTCNet 是 14.3 dB，而 IIANet 達到 16.0 dB，提升了 1.7 dB
在這個領域裡面，1 dB 以上的提升其實已經算是相當顯著的差距
接著看 LRS3，CTCNet 是 17.4，IIANet 是 18.3
而在最困難的 VoxCeleb2 上，CTCNet 是 11.9，IIANet 是 13.6，提升了 1.7 dB
也就是說，在三個資料集上都是全面超越
而且在最難的真實場景資料上，提升的幅度也最大
另外在語音品質的指標 PESQ 上
IIANet 分別是 3.23、3.28 跟 3.12，同樣都是最好的
值得注意的是輕量版的 IIANet-fast
它在 LRS2 是 15.1 dB，雖然比完整版低，但仍然明顯優於 CTCNet 的 14.3

Slide 15/21

接下來這一頁是效率的比較，也就是 Table 2
我覺得這其實是這篇論文最有說服力的一張表
先看計算量 MACs，CTCNet 需要 167.1 G，而 IIANet 只需要 18.6 G，大約只有 11%
參數量方面，CTCNet 是 7.0 M，IIANet 是 3.1 M，大約是 44%
GPU 記憶體佔用，CTCNet 是 75.8 MB，IIANet 只有 12.5 MB，大約是 16%
所以整體來說，IIANet 是用大約十分之一的計算量，換到更好的分離品質
而 IIANet-fast 更極端，MACs 只有 11.9 G，也就是 CTCNet 的 7%
在 CPU 的推論時間上，CTCNet 是 1.26 秒，IIANet-fast 只要 0.52 秒
大約快了 2.4 倍
不過這裡有一個要誠實指出的地方
完整版 IIANet 的 GPU 推論時間是 110.11 毫秒
其實比 CTCNet 的 84.17 毫秒還要慢
原因是 IIANet 的運算多是 Element-wise 的乘法，以及大量的分支連接
這類操作是 Memory-bound 的
也就是說它的瓶頸在記憶體搬移，而不是浮點運算
所以 MACs 的下降並沒有直接反映在 GPU 的延遲上

Slide 16/21

接下來這一頁是多說話者情境下的穩健性，也就是 Table 3
作者測試了 LRS2 上 2 人、3 人跟 4 人混合的情況
在 2 人混合時，CTCNet 是 14.3，IIANet 是 16.0
在 3 人混合時，CTCNet 掉到 10.3，IIANet 是 12.6
在 4 人混合時，CTCNet 是 6.3，IIANet 是 7.8
可以看到隨著說話人數增加，所有模型的表現都會下降，這是可以預期的
但重點是 IIANet 的領先幅度在每一種設定下都維持住了
在 3 人的情況甚至拉大到 2.3 dB
這說明多層級的融合在干擾源變多、聲學環境更混亂的時候，優勢反而更明顯

Slide 17/21

接下來這一頁是消融實驗，也就是 Table 4 跟 Table 5
先看 Table 4，作者設計了兩個 Control 組

Control 1 把 IntraA 跟大部分的 InterA 都移除，只保留最基本的連通，結果是 13.1 dB
Control 2 加回 IntraA，提升到 13.6 dB
也就是說模態內部的 Top-Down Attention 貢獻大約 0.5 dB
最後完整的 IIANet 加上 InterA，直接跳到 16.0 dB，貢獻了 2.4 dB
這個對比很清楚地說明
真正的效能來源是跨模態的多層級融合，而不是模態內部的注意力
接著看 Table 5，作者拆解了三個 InterA 的組合
如果只用單一個，InterA-M 的效果最好，達到 14.5 dB
這也呼應了每一個尺度都要融合這個核心主張
如果用兩個，Middle 加 Bottom 的組合最好，達到 15.5 dB
而三個全開才能達到 16.0 dB，所以這三個層級是互補的，並不是冗餘的

Slide 18/21

接下來這一頁整理了幾個放在附錄、但我覺得很值得一提的分析
第一個是 Appendix F，視覺資訊的貢獻
如果把視覺完全移除，只用音訊，效能是 11.2 dB，加入視覺之後是 16.0 dB
也就是說視覺線索本身值大約 4.8 dB，這證明了做視聽融合的必要性
第二個是 Appendix J，更換不同的 Video Encoder
作者試了 DC-TCN、MS-TCN 跟 CTCNet-Lip
結果分別是 15.7、15.8 跟 16.0，差距不到 0.3 dB
更有趣的是，唇讀的準確率跟分離品質並不是正相關的
準確率最高的 DC-TCN 反而分離效果最差
這說明怎麼融合，比用多好的視覺編碼器來得更重要
第三個是 Appendix K，側臉的情況
當說話者不是正面而是側臉時，AVLiT 跟 CTCNet 的效能下降超過 8%
而 IIANet 只下降大約 4%，側臉時仍然有 15.7 dB
第四個是 Appendix I，融合週期 N_F 從 1 增加到 5
效能在 4 次之後就飽和了，所以作者選擇 4
最後是 Appendix L，如果加上 Dynamic Mixture 這個資料增強
LRS2 可以從 16.0 提升到 16.8 dB，而每個 epoch 只多花 0.1 分鐘
這個性價比非常高，我認為是實作上很值得採用的一個技巧

Slide 19/21

接下來這一頁是整篇 Paper 的幾個核心觀察

第一，作者提出了 IIANet，把視聽融合從單一尺度推廣到多層級
並且在每一個層級都採用了對應的注意力機制
第二，它使用的是非常輕量的 Sigmoid Gating，而不是 Transformer 式的注意力
所以能在計算量只有前 SOTA 十分之一的情況下，反而取得更好的分離品質
第三，消融實驗清楚證明了三個層級的跨模態注意力是互補的
至於未來的方向，作者提到了幾點
包含把架構延伸到更多說話者、更長的音訊片段，以及嘗試在真實的端點裝置上部署

Slide 20/21

最後，我想提出幾點我對這篇論文的看法
第一個是事後的大腦類比
作者用視丘、A1、V1 這些神經科學的概念來包裝三個層級的注意力
這個敘事其實很吸引人
但論文裡面並沒有任何神經科學上的驗證，也沒有跟真實的神經活動做比對
所以我認為這更像是一個事後才套上去的解釋框架
而不是真正由神經機制推導出來的設計
換句話說，即使把這個類比拿掉，這個架構本身在工程上依然是成立的
第二個是數據描述的不一致
在摘要裡面，作者寫 IIANet-fast 的 CPU 推論快 40%
但在 Introduction 裡面卻寫快兩倍以上
如果去查 Table 2，實際的數字是 0.52 秒對 1.26 秒，也就是大約快 2.4 倍
所以摘要的那個 40%，應該是把只需要 40% 的時間誤寫成快 40%
這對讀者其實是會造成誤導的，我認為以 Table 2 的數字為準會比較恰當

Slide 21/21

接著是第三點，設計上的不對稱性
InterA-T 跟 InterA-B 都是雙向的
但中間層的 InterA-M 卻只有視覺到音訊這一個方向
作者雖然有給出解釋，說最終的輸出是音訊
但論文裡面並沒有做任何消融實驗，來證明移除音訊到視覺這條路徑是更好的選擇
所以這個設計選擇目前只有直覺上的說明，缺乏實驗支持
最後是這篇論文對我們研究的可轉移價值
我認為它最有參考價值的地方
是它證明了帶閘門的多尺度融合可以做得非常便宜

這一點是可以直接搬到 3D 醫學影像上的
例如 CT 或 MRI 的合成，或是多序列的分割任務
因為 3D 資料本身計算量就很大
用這種 Element-wise 的輕量融合，會比用 Transformer 的注意力實際得多
另外一個延伸方向是，把這裡的 Sigmoid Gating 換成 State Space Model，例如 Mamba
其實作者自己在論文中就引用了一個基於 SSM 的純音訊分離模型
所以這是一個很自然的接續方向
以上就是我今天的報告，謝謝大家