Slide 01/17

我今天要介紹的這篇 Paper 是 **Med-R1: Reinforcement Learning for Generalizable Medical Reasoning in Vision-Language Models**

這篇論文主要是在研究如何利用 Reinforcement Learning

去提升 Vision-Language Model 在醫療影像上的推理能力以及泛化能力

這篇 Paper 目前已經被 **IEEE TMI（Transactions on Medical Imaging）**接受發表

我會選這篇 Paper 來報告，主要是因為我們現在的研究，也打算利用 Qwen 模型的多模態能力

去處理影像跟文字結合的任務

而這篇論文也是以 **Qwen 的 Vision-Language Model** 作為基礎模型

所以我覺得這篇 Paper 跟我們目前的研究方向其實蠻相關的

因此想透過這次報告來了解它的研究方法和實驗結果

接下來我會先簡單介紹這篇 Paper 的研究背景，然後再說明作者提出的方法以及實驗結果

Slide 02/17

首先先看一下研究背景。

現在 Vision-Language Model 在很多任務上其實已經表現得很好

例如 Visual Question Answering 或 Multimodal Dialogue

不過當這些模型被用在**醫療影像**時，其實會遇到幾個問題

第一個問題是 **Supervised Fine-Tuning 的限制**

很多模型會學到資料中的表面 Pattern，而不是真的學會醫療推理

第二個問題是**醫療資料標註成本很高**

如果要做 Chain-of-Thought 的推理標註，通常需要醫師來完成，因此資料取得其實非常困難

第三個問題是**模型缺乏可解釋性**

很多模型只會給答案，但沒有清楚的推理過程

最後一個問題是**泛化能力不足**，很多模型只在單一影像模態表現好，但換到其他模態就會下降

Slide 03/17

為了解決這些問題，作者提出一個新的框架叫做 **Med-R1**

Med-R1 的核心想法是利用 Reinforcement Learning, RL

來提升 Vision-Language Model, VLM 的推理能力

和傳統的 Supervised Fine-Tuning, SFT 不同，RL 是透過 Reward Signal 來引導模型學習

因此模型可以探索不同的推理方式，而不是只依賴人工標註資料

作者在這裡使用的 RL 方法叫做 **GRPO，也就是 Group Relative Policy Optimization**
GRPO 是一種比較有效率的 RL 訓練方法，可以在不需要 Value Model 的情況下進行訓練

Slide 04/17

接下來簡單介紹 GRPO 的概念
在訓練的時候，模型會針對同一個問題生成多個回答
系統會根據這些回答的 Reward，去計算每個回答的相對優勢，也就是它的 Advantage
接著看一下 GRPO 的 Objective Function，它主要包含幾個部分
首先是 Policy Ratio
　　這個部分主要是用來衡量新舊的 Policy 之間的差異
接著是 Advantage Estimation，也就是 A_i
　　在 GRPO 中，Advantage 的計算方式是利用 Group 的 Reward 做 Normalization
　　也就是用一組回答的 Reward 來計算相對優勢
　　這一點和 PPO 使用 Value Model 來估計 Advantage 的方式是不同的

Slide 05/17

接下來這一頁主要是在補充 **GRPO Objective Function 裡面的另外兩個重要部分**
首先是 **Clipping Mechanism**
Clipping 的作用主要是**限制 Policy 更新的幅度**
　　也就是說，在訓練的過程中，如果新的 Policy 和舊的 Policy 差異太大
　　Clipping 會把更新的範圍限制在一個區間內
　　這樣可以避免模型在訓練時出現**過大的更新，導致訓練不穩定**
接下來是 **KL Divergence**
　　KL Divergence 的作用主要是**讓新的 Policy 不要偏離原本的 Reference Model 太多**
　　換句話說，就是在提升模型推理能力的同時，也要**保留原本模型的語言能力與知識**
　　因此透過 **Clipping Mechanism 和 KL Divergence**
　　GRPO 可以在提升模型 Performance 的同時
　　維持整體訓練過程的穩定性

Slide 06/17

接下來這一頁是在介紹 **GRPO 裡面 Advantage 的計算方式**
在 GRPO 的訓練過程中，模型會針對同一個 Prompt **生成 G 個不同的回答**

接著系統會利用這些回答的 Reward 來計算每個回答的 **Relative Advantage A_i**

在這篇 Paper 中，作者透過 **Group Normalization 的方式**來計算 Advantage

也就是把每一個回答的 Reward r_i 用整個 Group 的**平均值和標準差**來做標準化

公式就是這裡看到的

$$A_i = \frac{r_i - \text{mean}(r_{1\ldots G})}{\text{std}(r_{1\ldots G})}$$

透過這樣的方式，模型可以判斷某個回答**相對於同一組回答是比較好還是比較差**

另外一個重要的特點是

GRPO **不需要使用 Value Function** $V(s)$

因此可以大幅降低 **GPU Memory Overhead**，讓訓練變得更加有效率

在 Reward 的設計上，作者使用了兩種 **Rule-based Rewards**

第一個是 **Format Reward**，用來檢查模型是否正確使用 <think> 和 <answer> 這些標籤

第二個是 **Accuracy Reward**

也就是檢查模型的答案是否和正確的 MCQ 選項一致

透過這兩種 Reward，模型就可以同時學會**推理格式以及正確答案**

Slide 07/17

接下來這一頁是在介紹 **No-Think Reinforcement Learning**

在這個設定中，模型在回答問題時**不需要生成任何推理過程**，而是**直接從影像與問題中預測答案**

作者使用這個設定的目的，是把它當作一個 **Performance Upper Bound 的參考**

第一個重點是 **In-Domain Mastery，也就是對角線的位置**

在同一個影像模態的任務上，模型可以達到**接近滿分的準確率**

這代表模型在沒有 Reasoning 負擔的情況下可以發揮它的**最大辨識能力**

第二個重點是 **System-Wide Benchmark**

No-Think RL 可以看作是一個**理論上的性能上限**，也就是模型在沒有推理限制時

能夠做到的**最強醫療特徵提取能力**

因此作者使用 No-Think RL 來作為後續 **Reasoning 方法的比較基準**

Slide 08/17

接下來這一頁是在比較**三種不同的推理策略**

第一種是準確率 **72.57%** 的 **No-Think**

在這個策略中，模型**不會生成推理過程**，而是直接輸出答案

這種方式通常會有**最高的準確率**，因為模型只專注在 Prediction

第二種是 **Think**，模型會先生成 Reasoning，也就是推理過程，然後再輸出答案

第三種是作者提出的 **Think-After**

在這個策略中，模型**先輸出答案，再生成推理過程**

作者發現，Think-After 可以在 **Accuracy 和 Interpretability 之間取得比較好的平衡**

因為 Decision 和 Explanation 是分開生成的，因此 Reasoning 不會干擾模型的 Prediction

所以在醫療應用場景中，Think-After 其實是一個**比較實用的策略**

Slide 09/17

接下來這一頁會說明**為什麼 Think-After 的策略會表現比較好**

首先看第一個重點是 **Efficient Convergence**

如果看下面這兩張圖，左邊是 **CT dataset**，右邊是 **MRI Dataset**

可以看到 **Think-After 的曲線收斂速度比 Think 更快**，而且 Reward 也比較高

第二個原因是 **Optimization**

Think-After 的設計把 **Decision-making 和 Reasoning 解耦**

也就是模型**先做 Prediction，再生成 Explanation**，所以 Optimization 會比較穩定

第三個是 **Less Interference**

如果模型在回答之前就生成 Reasoning，這些 Reasoning 可能會**干擾 Autoregressive Generation**

導致 Prediction 不夠準確，而 Think-After 可以避免這種情況

最後是 **Medical Reliability**

Think-After 不但能保持不錯的 Accuracy

同時也能提供 Reasoning，因此在醫療場景中可以 **減少 Hallucination，同時保留可解釋性**

所以整體來說

Think-After 在 **Training Speed、Stability 和 Interpretability** 之間取得了一個比較好的平衡

Slide 10/17

接下來這一頁是在分析**不同醫療影像模態對模型泛化能力的影響**

作者發現，有些模態在訓練時對模型的學習效果特別重要，可以被視為 **Anchor Modalities**

首先是 **Training Leaders，也就是在訓練階段表現最好的模態**

在 **MRI 的準確率超過 74%，CT 超過 72%**，這兩種影像通常包含比較豐富的解剖結構資訊

因此可以提供比較穩定的醫療特徵

作者認為，這種**較高的解剖資訊密度**有助於模型學習跨模態的醫療特徵

接著是 **Testing Targets，也就是在測試時最容易被模型辨識的模態**

以 **OCT 和 X-Ray** 為例它們在測試中的準確率分別超過 **82%和 83%**

因此作者認為，這些模態在不同資料來源之間具有比較好的**特徵一致性**

Slide 11/17

接下來這一頁是在說明

模型在**跨模態泛化時的一些限制**

作者發現，有些影像模態，在跨模態任務中會出現**性能瓶頸**

第一個例子是 **Ultrasound**

Ultrasound 影像通常包含比較多 **Noise 和紋理模式**，因此模型比較難學到穩定的醫療特徵

第二個例子是 **Microscopy**

Microscopy 主要是**細胞層級的影像**，而像 CT 或 MRI 則是**器官層級的影像**

由於這兩種影像的尺度差異很大，模型在不同模態之間進行知識轉移時就會變得比較困難

因此作者認為，不同影像模態之間的**特徵尺度差異**，是跨模態泛化的一個重要挑戰

Slide 12/17

接下來這一頁是**一些實際案例的分析**，作者展示了模型在醫療影像問答任務中的一些推理過程

從這些例子可以看到，模型在回答問題時

會先觀察影像中的關鍵結構，然後逐步推理，最後給出答案

這些 Reasoning 在某些情況下其實和臨床醫師的診斷邏輯是有一定程度的相似

因此這些案例也顯示透過 RL 訓練，模型可以學會比較合理的推理過程

Slide 13/17

接下來這一頁是**醫療專家評估的結果**

作者邀請醫療專家，對模型生成的 Reasoning 進行評估

結果顯示，模型生成內容的 **Factual Quality** 平均大約在滿分 5 分中可以獲得 **4.25 分**

另外 **93.3% 的 Reasoning** 在邏輯上和答案是一致的

這表示模型不只是在做 Prediction，也能提供**人類可以理解的解釋**

這對醫療 AI 的應用其實非常重要

Slide 14/17

接下來作者也討論了一些限制

第一，目前模型主要是處理 **2D 醫療影像**

但在臨床實際應用中，很多醫療影像其實是 **3D 資料**，例如 CT 或 MRI

第二，目前任務主要是影像問答或識別任務

但真實臨床診斷通常還需要結合**病患病史或其他臨床資料**

因此未來的研究可以往**多模態醫療資料整合**的方向發展

Slide 15/17

接下來這一頁是整篇 Paper 的幾個**核心觀察**

首先，透過 **Reinforcement Learning** 可以有效提升 Vision-Language Model 在醫療影像上的推理能力

第二，作者提出的 **Think-After Strategy** 可以在**準確率與可解釋性之間取得平衡**

第三，即使是**比較小的模型**，透過 RL 訓練也可以達到非常好的 Performance

這也顯示在特定領域中，訓練策略有時候比單純增加模型規模更重要

Slide 16/17

最後這一頁是我在閱讀這篇 Paper 時的一些觀察和想法

第一個是 **Accuracy 和 Reasoning 之間的落差**

從實驗結果可以看到，其實 **No-Think RL 的準確率反而是最高的**

這代表在某些任務中，模型只需要做**影像特徵辨識**就可以得到正確答案

而不一定真的需要複雜的 Reasoning

所以這也讓人思考，在醫療影像任務中，**Reasoning 是否真的能提升 Prediction Performance**

第二個是 **Post-hoc Explanation 的風險**

在 Think-After 的策略中，模型是**先做 Prediction，再生成 Reasoning**

因此這些 Reasoning 有可能只是模型事後產生的解釋，而不一定是真正參與決策的推理過程

換句話說，這些 Explanation **不一定完全反映模型實際的 Decision Process**

第三個是**資料集本身的限制**

這篇 paper 使用的是 **OmniMedVQA Dataset**，它主要是 **Multiple-choice 的 VQA 任務**

因此很多問題其實比較像是在做**影像辨識或分類**，而不是真正的臨床診斷推理

所以模型的高準確率，某種程度上可能是來自 **Perception Ability**

而不一定代表完整的 Medical Reasoning 能力

最後是**未來可能的方向**

如果要讓模型更接近真實的醫療決策流程，未來可以考慮加入**更複雜的臨床任務**

例如結合影像、病史或 **EHR 資料**，這樣可能更能評估模型在實際醫療場景中的 Reasoning 能力