MedVLM-R1

以強化學習提升醫學視覺語言模型的推理與泛化能力

累百 PPT

作者？Conference？

Link to ppr？

Incentivizing Medical Reasoning Capability of Vision-Language Models via Reinforcement Learning

PI：論文名稱？ citation？

作者？机構？ keyword

https://github.com/JZPeterPan/MedVLM-R1

模型

Qwen2-VL-2B

訓練資料

600

方法

GRPO

群組相對策略最佳化

研究背景｜Medical VQA

影像 + 問題 → 答案：模型不只要看懂，也要回答正確

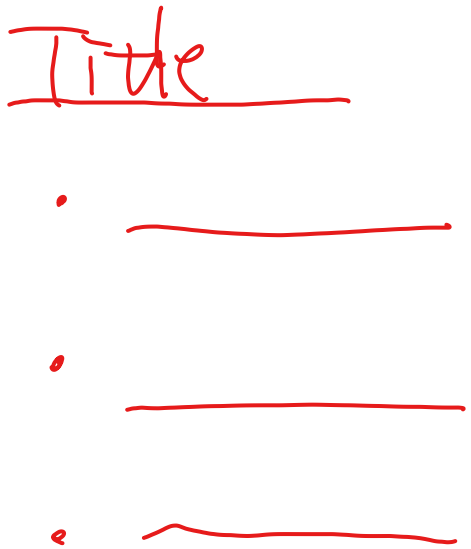
醫學影像
MRI / CT / X-ray

文字問題與選項

視覺語言模型 VLM

診斷選項與推理

- Medical VQA：以醫學影像為依據回答問題
- 本研究聚焦「選擇題」，不是完整臨床診斷系統



研究缺口｜SFT 的限制

問題 1

泛化落差

MRI 訓練後，CT / X-ray 表現可能下降

問題 2

推理品質

學會最終選項 ≠ 學會合理判斷

研究方向

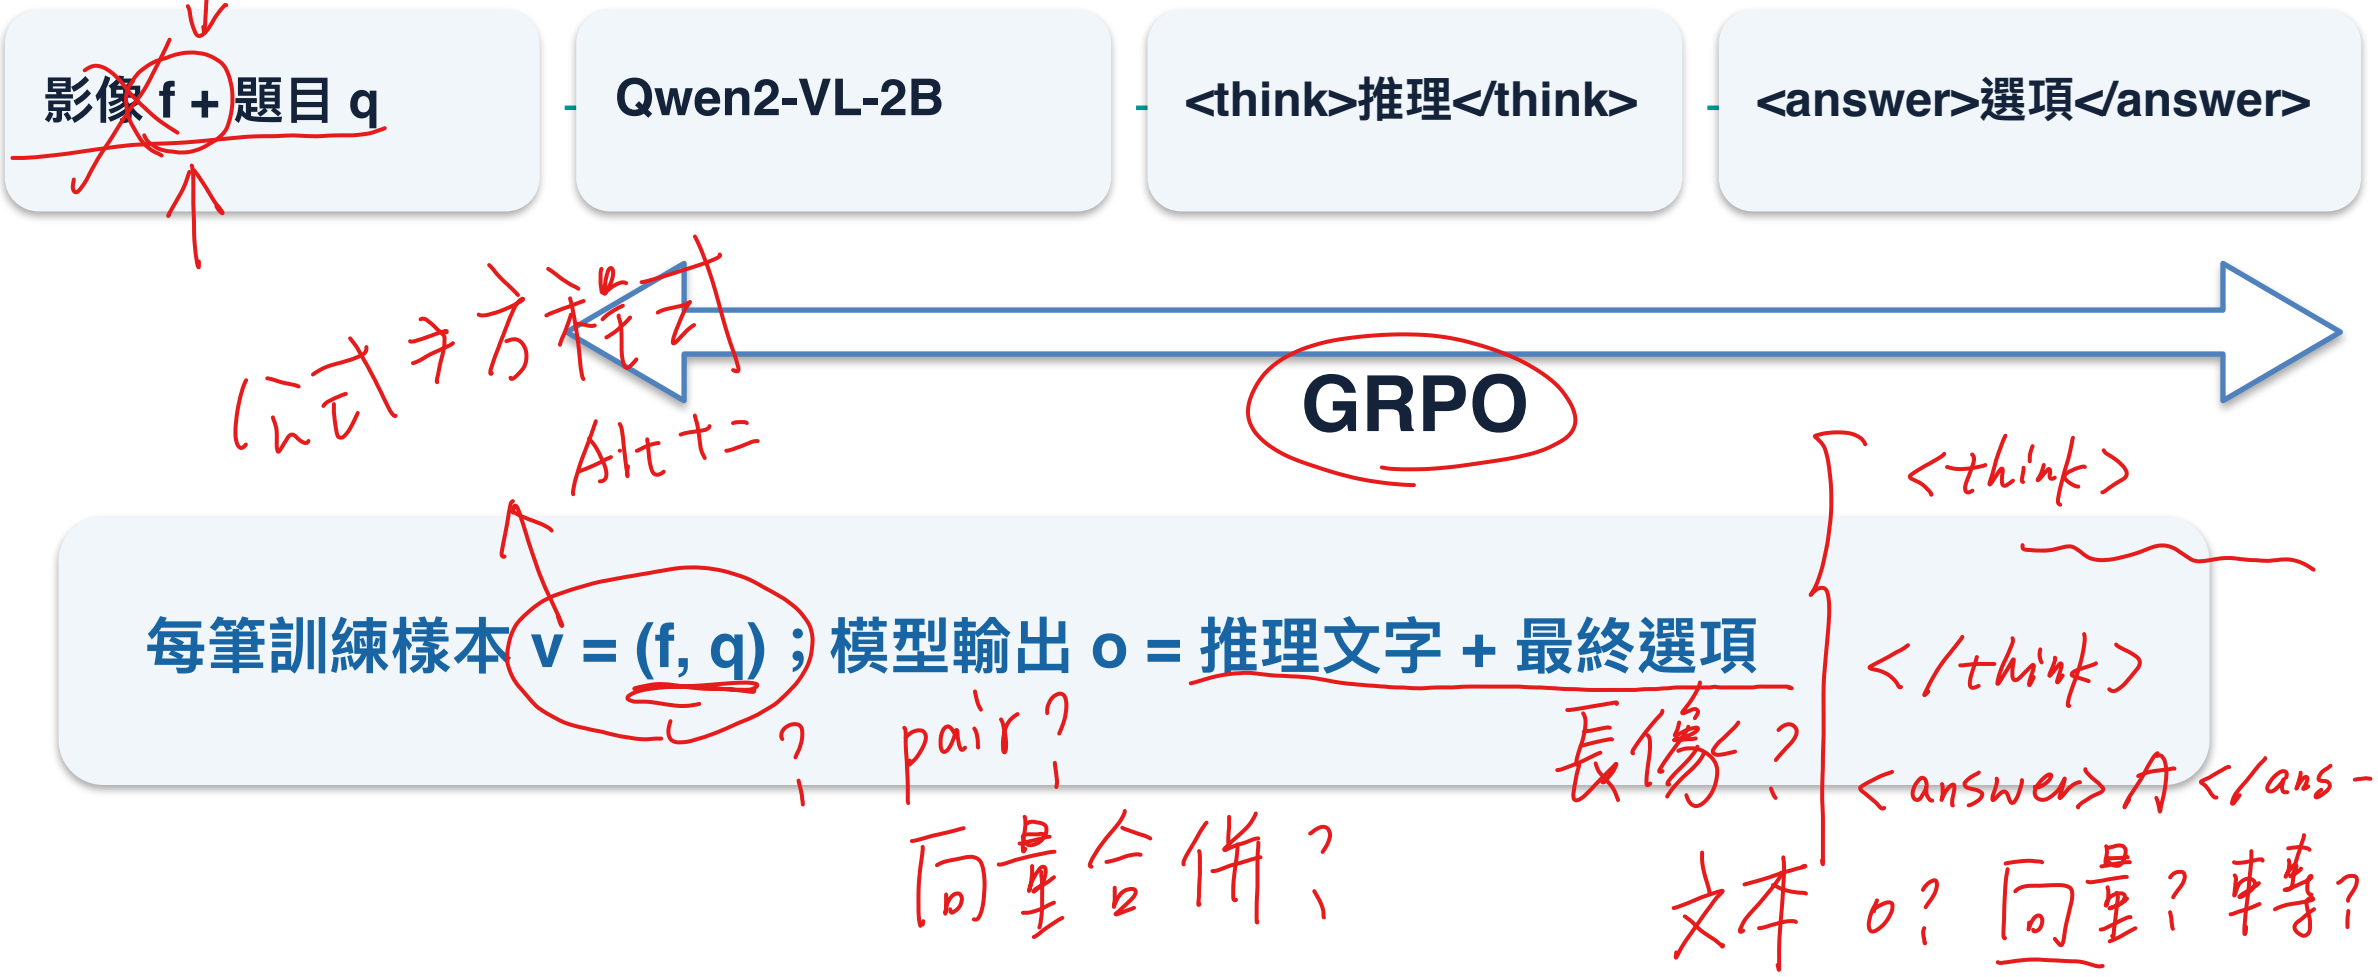
Reinforcement Learning

用答案與格式獎勵改善輸出

研究貢獻｜MedVLM-R1

- 以 Qwen2-VL-2B 為基礎，將 GRPO 引入放射影像選擇題 VQA
- 只使用 600 筆 MRI 資料進行強化學習
- 以規則式 Format + Accuracy Reward 訓練，無需人工推理標註
- 測試 MRI（ID）、CT 與 X-ray（OOD），檢驗泛化能力

方法總覽｜輸入與輸出


影像 f + 題目 q
Qwen2-VL-2B
<think>推理</think>
<answer>選項</answer>
GRPO
每筆訓練樣本 v = (f, q)；模型輸出 o = 推理文字 + 最終選項

GRPO 訓練流程｜Group Relative Policy Optimization

同一題目 v → 採樣 G = 6 回答（作者設定） → 計算每個 Reward r_i → 群組標準化 A_i → 更新 $\pi\theta$

- 不額外訓練 Value Model；直接利用群組內候選答案的相對表現
- 高於群組平均的輸出受到鼓勵，低於平均的輸出被抑制

GRPO 公式 ①｜群組相對優勢

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \cdots, r_G\})}{\text{std}(\{r_1, r_2, \cdots, r_G\})}$$

個別獎勵 - 群組平均

標準差

r_i：第 i 個候選答案的獎勵；G：候選答案數（本文 G = 6）

高於平均

$A_i > 0$

增加相對偏好

低於平均

$A_i < 0$

降低相對偏好

GRPO 公式 ②｜策略比率與裁切

$$r_i^{\text{ratio}} = \frac{\pi_\theta(o_i|\boldsymbol{v})}{\pi_{\theta_{\text{old}}}(o_i|\boldsymbol{v})}$$

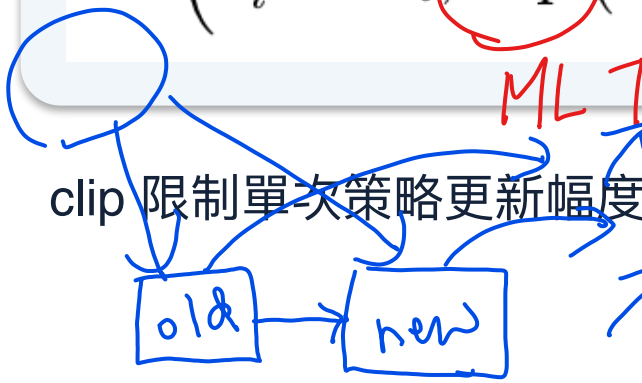
新方向

舊方向

πθold：產生候選回答時的舊策略；πθ：目前更新中的策略

$$\min\left(r_i^{\text{ratio}} A_i, \text{clip}\left(r_i^{\text{ratio}}, 1 \pm \epsilon\right) A_i\right)$$

clip 限制單次策略更新幅度；ε 控制裁切範圍。



GRPO 公式 ③｜完整最佳化目標

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}_{\boldsymbol{v}\sim P(\boldsymbol{V})}\mathbb{E}_{\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{old}}(\cdot|\boldsymbol{v})}$$

$$\frac{1}{G}\sum_{i=1}^{G}\left[\min\left(r_i^{\text{ratio}}A_i, \text{clip}\left(r_i^{\text{ratio}}, 1\pm\epsilon\right)A_i\right) - \beta\mathbb{D}_{KL}\left(\pi_\theta||\pi_{ref}\right)\right]$$

- KL divergence：限制目前模型與參考模型 πref 的差距，減少過度偏移
- β：KL 懲罰權重；ε：裁切係數；論文公式 (3.1)

Reward 設計｜兩部分規則式獎勵

Reward	判定條件	分數
Format	<think>、<answer> 各標籤完整且無標籤外文字	1
Format	缺漏、重複或有多餘標籤外文字	0
Accuracy	選項字母完全正確	1
Accuracy	選項正確，但含額外說明 / 改用選項內容	0.5
Accuracy	選項錯誤或無法抽取	0

總獎勵：$r_i = R_format + R_accuracy \in [0, 2]$

輸出範例｜為何需要格式獎勵

<think>

這是一張 MRI；依影像特徵判斷病灶…

</think>

<answer>

B

</answer>

Problem 1: What can be observed in this image?

A) Lungs B) Bladder C) Brain D) Heart

MedVLM-R1 Output:

<think>
The image is a chest X-ray, which is a type of radiographic image used to visualize the internal structures of the body, particularly the lungs and bones. The presence of lung markings and the ribcage are characteristic features of a chest X-ray.
</think>

<answer>A</answer> **Groundtruth Answer: A**



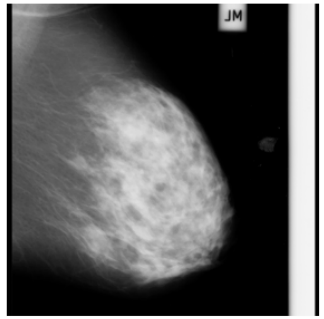
Problem 2: What content appears in this image?

A) Cardiac tissue, B) Breast tissue, C) Liver tissue, D) Skin tissue

MedVLM-R1 Output:

<think> The image appears to be a mammogram, which is a type of X-ray used to detect abnormalities in the breast tissue. The image shows the breast tissue with various densities and patterns, which are typical of mammograms. </think>

<answer>B</answer> **Groundtruth Answer: B**



- 格式完整、選項正確 → Format 1 + Accuracy 1 = 2
- 若答案為「B，因為…」→ 格式可能仍合格，但 Accuracy 僅 0.5
- 重要：Reward 未逐步驗證 <think> 中的醫學推理是否正確

資料集與測試設定

訓練

600 MRI

僅使用 MRI 選擇題

ID 測試

300 MRI

同模態

OOD 測試

300 CT + 300 X-ray

跨模態泛化

- 資料來源：HuatuoGPT-Vision 評估資料；以 MRI 訓練、CT / X-ray 測試
- ID = In-Distribution；OOD = Out-of-Distribution

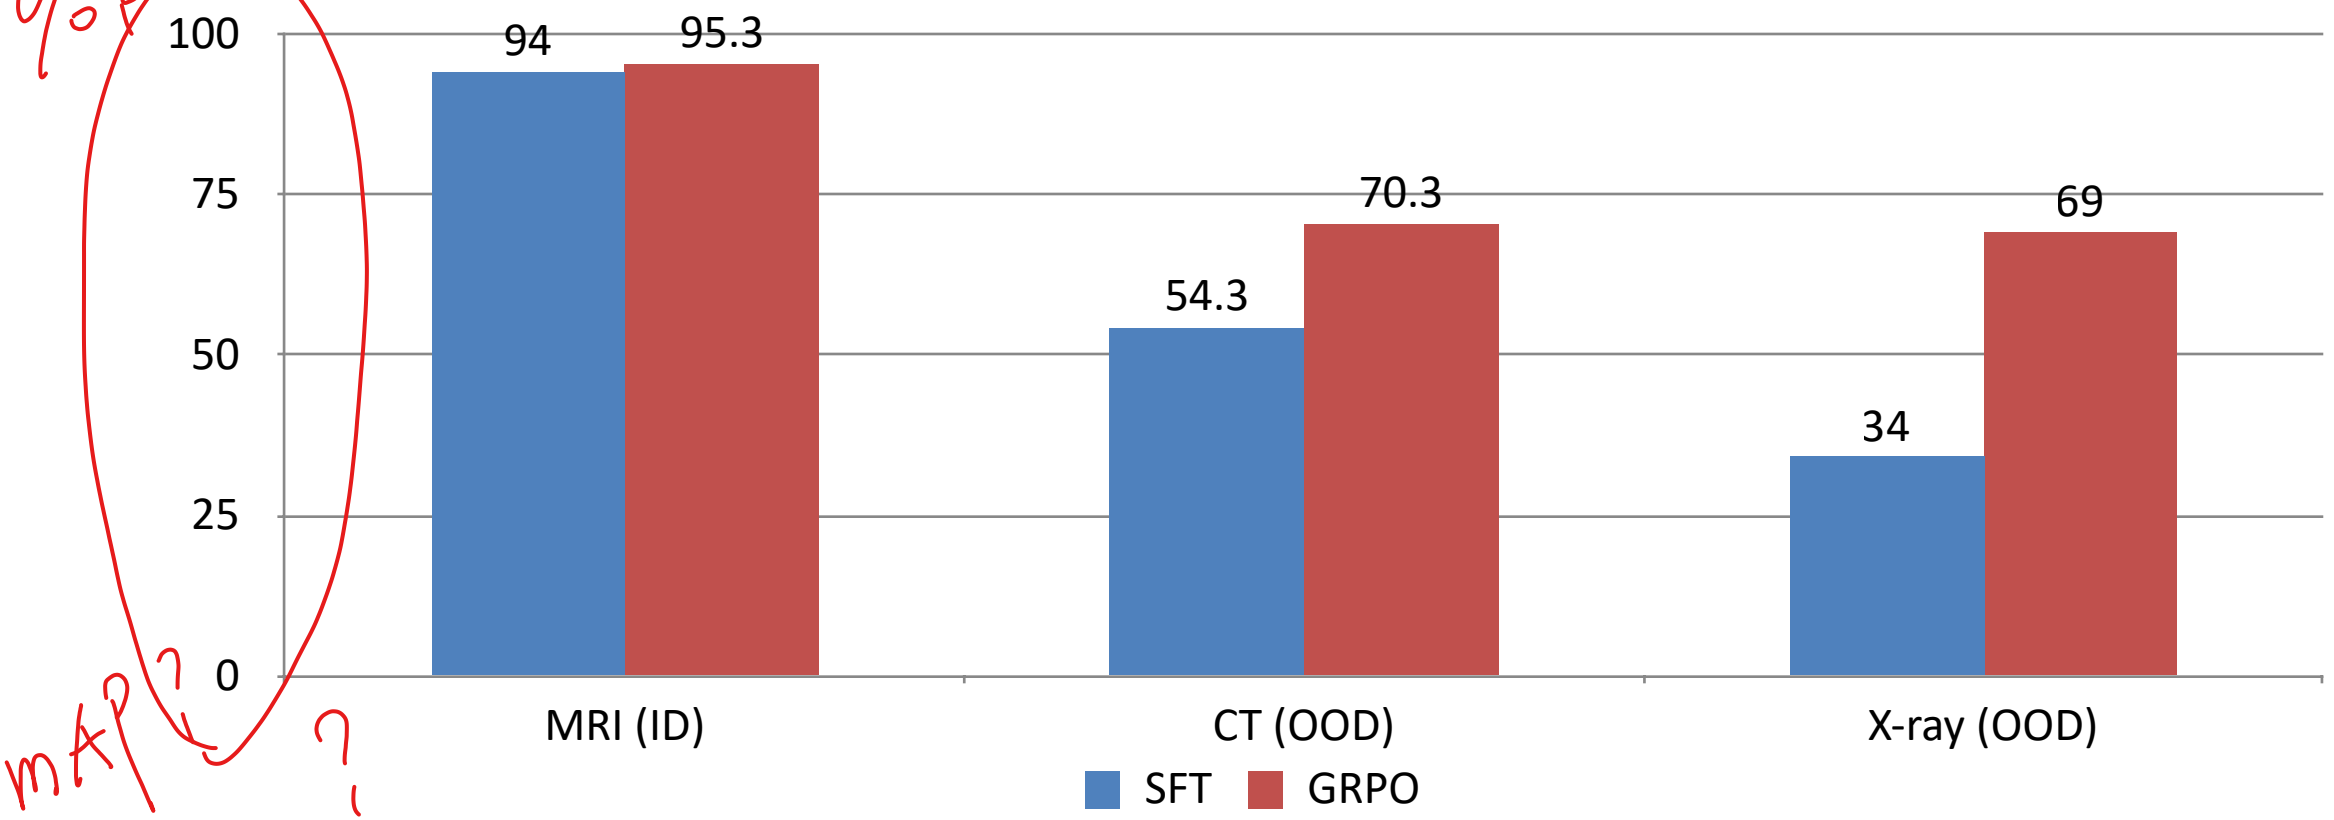
訓練設定與比較基準

設定	內容
Base model	Qwen2-VL-2B
強化學習	GRPO；每題採樣 G = 6 個候選輸出
對照組	相同 600 筆 MRI 的 SFT
其他比較	Zero-shot Qwen2-VL、HuatuoGPT-Vision
運算	2 × NVIDIA A100；約 300 steps、約 4 小時



主要結果｜MRI / CT / X-ray 準確率

結論：GRPO 對 CT +16.00 pp、X-ray +35.00 pp；OOD 提升最明顯



- 作者使用的是 HuatuoGPT-Vision 的醫學多模態評估資料集，並非自行招募病患、重新拍攝 600 張 MRI。
  評估資料集整合了多個公開醫學視覺問答資料來源，例如 VQA-RAD、SLAKE、PathVQA、OmniMedVQA、PMC-VQA 等。
  MedVLM-R1 從中挑選 MRI、CT 和 X-ray 類型的影像問答資料。

完整結果｜與其他模型比較



模型	醫學樣本	MRI	CT	X-ray	平均
Random Guess	—	25.00	30.25	26.00	27.08
Qwen2-VL-2B (zero-shot)	—	61.67	50.67	53.00	55.11
Qwen2-VL-7B (zero-shot)	—	72.33	68.67	66.63	69.21
Qwen2-VL-72B (zero-shot)	—	68.67	60.67	72.33	67.22
HuatuoGPT-Vision-7B	1,294,062	71.00	63.00	73.66	69.22
Qwen2-VL-2B (SFT)	600	94.00	54.33	34.00	59.44
MedVLM-R1 (GRPO)	600	95.33	70.33	69.00	78.22

單位：Accuracy (%)；資料：原論文 Table 1

平均準確率｜最重要的定量結論

SFT 平均

59.44%

600 MRI 訓練

GRPO 平均

78.22%

600 MRI 訓練

絕對提升

+18.78 pp

百分點，而非相對百分比

- MRI 同分布測試僅 +1.33 pp，跨模態 CT / X-ray 的改善更具代表性
- 這是特定選擇題資料集的結果，不能直接推論臨床診斷可靠性

Reasoning 案例｜推理與答案的落差

簡單案例

合理描述

X-ray 問題中推理較符合影像特徵

複雜案例

排除選項

MRI 問題有時缺乏細緻影像分析

潛在風險

事後合理化

CT 案例可能答案正確但解釋鏈不足

「產生推理文字」不等於「推理已被驗證」

限制｜作者明確指出的問題

- Modality gap：病理影像與 OCT 等模態無法順利收斂
- Closed-set dependence：開放式問答表現顯著下降
- Superficial reasoning：可能有空泛推理或推理與答案不一致
- Model scale：2B 模型容量可能限制複雜醫學推理

結論｜Takeaways

- 方法：Qwen2-VL-2B + GRPO + 規則式雙重獎勵
- 數據：600 MRI 訓練，平均準確率 59.44% → 78.22%
- 泛化：CT +16.00 pp；X-ray +35.00 pp
- 限制：有 <think> 輸出，但推理忠實度尚未證明

Reference: Pan et al., MedVLM-R1, arXiv:2502.19634v2 (2025)