Learning RoI Transformer for Oriented Object Detection in Aerial Images

論文：Jian Ding, Nan Xue, Yang Long, Gui-Song Xia, Qikai Lu, "Learning RoI Transformer for Oriented Object Detection in Aerial Images", CVPR 2019, pp. 2849–2858.

預印本：https://arxiv.org/abs/1812.00155 ／

官方程式碼：https://github.com/dingjiansw101/RoITransformer_DOTA

Introduction

今天我要分享的論文是發表在 CVPR 2019 的 Learning RoI Transformer for Oriented Object Detection in Aerial Images 屬於衛星空拍影像的物體辨識這個領域。首先，我們來看看『航拍影像的物件偵測』面臨什麼樣的挑戰。與一般照片不同，空拍圖是鳥瞰視角，裡面的車輛、船隻通常是密集排列，且方向隨意無規律。過去的傳統做法（例如 Faster R-CNN）通常使用『水平框 (HRoI)』來框選物件。請大家看到左邊的圖，當車子斜向停放且非常密集時，一個紅色的水平框裡面，往往會擠進好幾台車的特徵 。這會讓神經網路非常困惑，因為特徵與真實物件產生了嚴重的『不對齊(Misalignment)』，導致模型很難精準判斷這到底是一台大卡車，還是兩台小汽車。

為了解決這個問題，傳統的做法是直接讓模型預測帶有角度的『旋轉框 (RRoI)』。但這些方法由於必須在圖片上鋪滿各種角度、長寬比的 Anchor，這讓計算量跟記憶體消耗變得非常可怕。因此，本篇論文提出了一個非常輕量化的解決方案：RoI Transformer。

Method

它的核心思想很簡單：一樣是先用計算成本低的 Horizontal 水平框來抓出大約的位置，接著，透過一個 learnable network module，讓模型自己學會把『水平框』變形、旋轉成完美貼合車身的『旋轉框』。

這個 Transformer 主要由兩個模組組成：第一個是 RRoI Learner，第二個是

後續的 RRoI Warping。RRoI Learner 的任務就是負責把一開始粗略的『水平框(HRoI)』，轉換成貼合物件的『旋轉框 (RRoI)』。作者在這裡採用了輕量化的設計，它只透過一個 Fully Connected Layer (全連接層)，去學習 5 個幾何偏移參數 x, y, w, x, θ，分別是中心點座標、長寬以及『旋轉角度θ』。論文中用了三角函數來推導這些偏移量。

Relative Offset 將旋轉綁定在物件上：如果用影像的全域座標，同一種相對位置在不同旋轉角度的框上會算出不同數字，網路學不動。解法是把位移向量乘上負 theta 的旋轉矩陣，換算到綁在旋轉框自己身上的局部座標系，再除以邊長正規化。寬高和角度的處理方式和一般框回歸一樣，就不贅述。把 theta_r 代 0，這條式子就退化成一般 Faster R-CNN 的回歸目標，剛好對應第一階段還是水平框的情況。當 RRoI Learner 成功預測出帶有角度的旋轉框之後，下一步就是要提取特徵。這時候我們就要用到第二個核心模組：RRoI Warping (具體實現為 Rotated Position Sensitive RoI Align) 。做法是在旋轉框自己的局部座標裡切出 K 乘 K 個 bin，再把每個取樣點旋轉平移回特徵圖上的位置，因為落點通常不是整數座標，用雙線性插值取值，所以整個操作可微。這裡有個容易忽略的細節：輸出第 i、j 格只讀對應的那一張通道，這個通道對應規則是從 R-FCN 沿用下來的 position sensitive 設計。結果就是不管物體原本朝哪個方向，抽出來的特徵都被轉正、對齊了。

這張是完整流程，我把論文 Figure 2 沒標的維度補上去。影像先切成 1024 見方的 patch，過 ResNet-101 骨幹，再接 light-head 的 large separable convolution，得到一張 490 通道的薄特徵圖。490 這個數字不是隨便來的，它是 K 乘 K 乘 C，也就是 7 乘 7 乘 10，這點論文只在實驗設定裡提到超參數，圖上完全沒寫，所以第一次看會卡住。接著 RPN 用 15 個水平 anchor 產生候選框，NMS 後留 800 個。然後才進入 RoI Transformer，先做 RRoI Learner 再做 RRoI Warping。要特別注意 RoI-wise 的操作在這裡做了兩次，一次是為了學旋轉參數、一次是為了抽最終特徵，這是它和 deformable RoI pooling 結構上最像的地方。最後接一層 2048 維全連接，分岔成分類和旋轉框回歸。

Dataset

第一個是 DOTA，它是目前最大的空拍圖旋轉物件資料集，包含超過 18 萬個密集且方向各異的實例，涵蓋了飛機、大型車輛等 15 種分類。第二個則是專門針對船隻偵測的 HRSC2016 資料集，船隻的特性就是「細長」且「方向極端隨

機」。

接著進入到 DOTA 的資料預處理 (Preprocessing)。原始的空拍圖往往非常巨大，無法直接塞進神經網路。因此，作者將圖片裁切成 1024x1024 的區塊。Stride (步長)設定為 824。因為 824 小於圖片寬度 1024，這代表每一張切出來的小圖，都會跟上一張有部分重疊(Overlap)。這樣設定它可以有效避免位在圖片裁切邊界上的卡車或飛機被硬生生切成兩半，導致模型無法辨識。最後，為了平衡部分類別樣本數過少的問題，作者也加入了不同比例的縮放，以及 4 個角度 (0, 90, 180, 270 度) 的旋轉增強 (Data Augmentation)，藉此強化模型的泛化能力 。

HRSC2016 船隻資料集上，處理方式稍微不同。為了讓模型適應不同航向的船隻，作者使用了『水平翻轉 (Horizontal flipping)』來做資料擴增。此外，為了解決空拍圖長寬比差異極大的問題，他們將影像縮放至 (S, M) = (512, 800)。這代表系統會優先將影像短邊縮放至 512 像素；但如果等比例放大後導致長邊過長，就會強制將最長邊限制在 800 像素以內。

Results

HRSC2016 是一個專門針對「船隻」的資料集。。這張表要證明的是：RoI Transformer 處理極端長寬比的能力很強。面對極度密集、微小的物件（例如小型車輛、大型車輛、船隻）時，RoI Transformer 的表現幾乎是輾壓全場的 。大家可以特別尋找表格中的『Ship (船隻)』類別，我們單在這一項的準確度，就比先前的最佳紀錄（ICN 模型）大幅提升了 13.61% ！

首先，這篇論文選用的 Baseline 叫做 Light-Head R-CNN OBB。簡單來說，它是一個運算速度非常快的主流物件偵測框架，並且在這裡被作者修改成可以預測帶有角度的『旋轉框』。 接著，作者找來了一個對手進行比較：deformable PS RoI pooling (我們簡稱 DPSRP)。這個技術的特色是網格可以『自由變形』，透過學習額外的偏移量，來貼合各種形狀怪異的物件。 Baseline、強勁對手 DPSRP 以及我們 RoI Transformer，這三者都試圖解決『特徵不對齊』的問題，在充滿密集卡車與船隻的空拍圖為題目來一較高下。

接下來我們進入實驗結果與分析的部分。首先，我們來看最關鍵的整體效能與計算複雜度對比。請大家看到 Table 1，我們的 Baseline（Light-Head R-CNN OBB）準確度是 58.3% 。當引入了強大的 deformable PS RoI pooling (DPSRP) 後，mAP 提升了 5.6%，達到 63.89% 。這證明在航拍影像中，幾何形變建模的

方式是影響分數的其中一個因素。但是，我們的 RoI Transformer (RT) 表現更強，mAP 來到 67.74%。再來看到速度與參數量。我們的模型參數量與 DPSRP 完全一致，都是 273MB 。在單張圖推理速度上，DPSRP 需要 0.206 秒，而我們的 RoI Transformer 僅需 0.17 秒，運算速度反而更快 ！ 這都歸功於 RRoI Learner 輕量化的 network design，使其需要學習了 5 個參數，而 DPSRP 則需要學習 7×7×2 = 98 個偏移參數 。在密集的卡車停車場中，Baseline 和 DPSRP 因為特徵不對齊，定位非常混亂，甚至把紅色卡車的車頭誤判成了藍色框的小汽車 。而 RoI Transformer 預測的旋轉框不僅最貼合，且幾乎沒有任何誤判 。」

Ablation Study

原本的 Baseline 只有 58.3%。當我們單純加入剛剛提到的『RRoI Learner』把水平框轉成旋轉框後，mAP 直接跳升到 63.17%，證明了解決特徵不對齊是極度有效的。接著，作者發現了一個有趣的現象：如果框切得『太剛好』，反而會缺少判斷的線索 。所以他們把旋轉框適度『放大』了一點點（長邊 1.2 倍、短邊 1.4 倍），納入周圍的環境 Context，這讓準確率又提升了近 3% 。 最後，作者選擇『不對』產生的旋轉框做 NMS：它會保留信心分數最高的那一個框，並把周圍跟它高度重疊的其他框刪掉，確保一個物件最終只有一個框。實驗結果發現：如果不做 NMS（移除 NMS 步驟），mAP 反而會提升 1.5% 。作者在論文中解釋，這是因為不做 NMS 可以保留更多的候選框，進而增加了「召回率 (Recall)」，也就是提高了找回所有真實物件的機率 。

Conclusion

最後，我們來為這篇論文做個總結，並探討作者在實驗中觀察到的限制。總結來說，本篇論文提出了 RoI Transformer 來進行幾何轉換的建模，這個做法有效地解決了區域特徵與真實物件『不對齊 (misalignment)』的問題 。這個設計不僅在 DOTA 和 HRSC 兩個具挑戰性的資料集上帶來顯著的準確度提升，而且幾乎沒有增加額外的運算成本 。實驗也證實，當有旋轉框標註可用時，這個模型比 deformable RoI pooling 更加合理且有效 。 不過，論文中也展示了模型目前的限制。Figure 5 左圖模型將船隻在水面上的尾跡誤判成了港口；右圖則將港口的結構誤判成了飛機 。 作者在論文中指出，發生這些錯誤的原因在於，目前的模型並沒有學習到場景的脈絡 (context)，這也是該模型目前尚未考慮到的部分 。 我的報告到此結束，謝謝大家！

Appendix

📦 第一群組：基礎邊界框與定位標註（最底層的觀念）

在進入神經網路前，我們必須先定義「如何框出物體」：

HBB (Horizontal Bounding Box) / AABB (Axis-Aligned Bounding Box)：水平邊界框

（四個邊永遠平行於圖片邊緣）。

OBB (Oriented Bounding Box)：定向邊界框 / 旋轉邊界框

（帶有旋轉角度 θ 的框

）。

IoU (Intersection over Union)：交併比

（評估兩個框重疊程度的指標，公式為重疊面積除以總面積

）。

📦 第二群組：感興趣區域與候選框（特徵提取的媒介）

神經網路在圖片中「框選」出可能含有目標物的區域：

RoI (Region of Interest)：感興趣區域

（神經網路認為可能有物體的候選區域）。

HRoI (Horizontal Region of Interest)：水平感興趣區域

（水平的候選框

）。

RRoI (Rotated Region of Interest)：旋轉感興趣區域

（帶有角度、貼合傾斜物體的候選框）。

RPN (Region Proposal Network)：區域候選網路

（在第一階段快速撒下預設框、找出初步 RoI 的輕量網路

）。

📦 第三群組：這篇論文的核心架構（RoI Transformer 雙核心）

論文提出的兩大核心模組，用來把水平框變形並提取無損特徵：

RRoI Learner：旋轉候選區域學習器

（利用輕量全連接層，從 HRoI 學習並預測其對應的 RRoI 幾何偏移參數

）。

RPS RoI Align (Rotated Position Sensitive RoI Align)：旋轉位置敏感的感興趣區域對齊

（本篇論文採用的具體 RRoI Warping 方式，用來在旋轉網格上提取「旋轉不變性特徵」

）。

📦 第四群組：比較對手與輔助套件（實驗中的對照組與外掛）

用來和本文方法互相傷害（對比）或互相合作的技術：

DPSRP (Deformable Position Sensitive RoI Pooling)：可變形位置敏感 RoI 池化

（利用無監督學習偏移量讓網格自由變形的強勁對手

）。

NMS (Non-Maximum Suppression)：非極大值抑制

（消除重複多餘預設框、保留信心度最高框的後處理演算法

）。

FPN (Feature Pyramid Networks)：特徵金字塔網路

（融合不同深淺層特徵、處理多尺度目標的網路增強結構

）。

📦 第五群組：資料集與效能評估

DOTA：大型航拍影像物件偵測資料集

（包含 15 個類別、18 萬個任意方向密集物體

）。

HRSC2016：高解析度船隻資料集

（專門針對各種外觀、任意角度船隻的檢測資料集

）。

mAP (Mean Average Precision)：平均精度均值

（評估物件偵測模型好壞的黃金標準分數）。

SOTA (State-of-the-art)：最先進的技術/表現

（指某個領域中目前最強、分數最高的模型

）。